UNIVERSIDAD EUROPEA DE MADRID

ESCUELA DE ARQUITECTURA, INGENIERÍA Y DISEÑO

GRADO EN FÍSICA

TRABAJO FIN DE GRADO

APLICACIÓN DE TENSOR NETWORKS EN MODELOS DE IA PARA CLASIFICACIÓN DE IMÁGENES

MANUEL ARENAS SÁNCHEZ

Dirigido por

ALEJANDRO MATA ALI

MARÍA FUENCISLA GILSANZ MUÑOZ

CURSO 2025-2026

TÍTULO: APLICACIÓN DE TENSOR NETWORKS EN MODELOS DE IA PARA CLASIFICACIÓN DE IMÁGENES

AUTOR: MANUEL ARENAS SÁNCHEZ

TITULACIÓN: GRADO EN FÍSICA

DIRECTOR/ES DEL PROYECTO: ALEJANDRO MATA ALI
MARÍA FUENCISLA GILSANZ MUÑOZ

FECHA: MARZO DE 2026

RESUMEN

ESTO SE ESCRIBE AL FINAL DEL PROYECTO

ABSTRACT

Porque se escribe esta parte en ingles??

Keywords: Palabras clave en inglés

AGRADECIMIENTOS

Se escribe al final del proyecto

Cita - frase célebre / Dedicatoria

Escribiré algo al final del proyecto

TABLA RESUMEN

[Rellena esta tabla, y borra la opción que no aplica. Si tu proyecto ha tenido tanto desarrollo de producto como investigación, haz constar "SI" en ambos casos]

	DATOS
Nombre y apellidos:	Manuel Arenas Sánchez
Título del proyecto:	Aplicacion de Tensor Networks en modelos de IA para clasificación de imágenes...
Directores del proyecto:	Alejandro Mata Ali y Maria Fuencisla Gilsanz
El proyecto se ha realizado en colaboración de una empresa o a petición de una empresa:	SI
El proyecto ha implementado un producto: (esta entrada se puede marcar junto a la siguiente)	NO
El proyecto ha consistido en el desarrollo de una investigación o innovación: (esta entrada se puede marcar junto a la anterior)	SI
Objetivo general del proyecto:	[...una frase...]

ÍNDICE

RESUMEN **4**

ABSTRACT **5**

AGRADECIMIENTOS **6**

TABLA RESUMEN **8**

1 INTRODUCCIÓN / ESTADO DEL ARTE **13**

1.1 Introducción a Deep Learning 13

1.2 Introducción a Tensor Networks 15

1.2.1 Concepto de tensor 15

1.2.2 Notación diagramática 17

1.2.3 Introducción a las Tensor Networks 18

2 OBJETIVOS **20**

2.1 Objetivos generales 20

2.2 Objetivos específicos 20

2.3 Objetivos que quedan fuera del proyecto 21

2.4 Beneficios del proyecto 21

3 DESARROLLO DEL TFG **23**

3.1 Planificación del trabajo fin de grado 23

3.2 Descripción de la solución, metodologías y herramientas empleadas 25

3.2.1 Recursos requeridos 25

3.3 Resultados del TFG 25

4 DISCUSIÓN **26**

5 CONCLUSIONES **27**

5.1 Conclusiones del trabajo 27
5.2 Conclusiones personales 27

6 FUTURAS LÍNEAS DE TRABAJO **28**

REFERENCIAS **29**

ANEXOS **30**

ÍNDICE DE FIGURAS

1.1 Representación de las redes neuronales más comunes y simples. Empezando por el perceptrón, que fue el primer modelo de red neuronal propuesto en el año 1958 por Frank Rosenblatt, hasta llegar a modelos más modernos como las RNN. Fuente: [1]. 14

1.2 Ejemplo de representación diagramática para un tensor. Fuente: [2] 18

3.1 Planificación por semanas del TFG, cada circulo representa una semana teniendo febrero 3 semanas (porque empiezo el 9 de Febrero), marzo 4 semanas, abril cuatro semanas y por último mayo tendrá otras cuatro semanas. De esta manera se cumplen entre 500 y 600 horas dedicadas al TFG. 23

ÍNDICE DE TABLAS

Todas las tablas incluidas en la memoria deben estar referenciadas para incluir en este índice.

Capítulo 1. INTRODUCCIÓN / ESTADO DEL ARTE

1.1 Introducción a Deep Learning

El término *Deep Learning* nació de la necesidad de dar un nuevo nombre a las redes neuronales. No es más que una red neuronal con múltiples capas de transformación lineal entre la entrada y la salida. Con lo cual es importante entender antes el concepto de redes neuronales.

El origen de redes neuronales se remontan a la primera mitad del sigo XX, cuando los investigadores comenzaron a plantearse la posibilidad de modelar computacionalmente el funcionamiento del cerebro humano. Los primeros modelos fueron propuestos en 1943, pero estas arquitecturas carecían de capacidad de aprendizaje [3]. Pocos años después, en 1949 Hebb sentó las bases del aprendizaje en redes neuronales. Hebb postuló que, la conexión entre dos neuronas se refuerza cuando ambas se activan simultáneamente, concepto que hoy en día se conoce como la regla de Hebb. Sin embargo, no fue hasta el año 1986, en el que de verdad surgió un interés notable en las redes neuronales. Rumelhart, Hinton y Williams, demostraron que las redes de varias capas podían aprender representaciones internas útiles para resolver problemas de mayor complejidad [3]. Este hito abrió la puerta a las arquitecturas de redes neuronales más sofisticadas, que vendrían décadas después.

Una red neuronal es una estructura computacional formada por un conjunto de unidades de procesamiento simples, denominados neuronas. Éstas están interconectadas mediante pesos sinápticos ajustables, llamados en inglés *weights* y *biases*. Cada neurona recibe una serie de entradas, a las cuales llamaremos *inputs*; se calcula una suma ponderada de las mismas y se les aplican una función de activación –generalmente no lineal– para producir una salida, la cual llamaremos *output*. El comportamiento de la red, queda determinado por los valores de estos pesos, que son modificados durante el entrenamiento con el objetivo de minimizar una función de error entre los *outputs* y las respuestas esperadas.

Las redes neuronales se pueden clasificar según la topología de sus conexiones. Las redes *forward-propagation* (propagación hacia delante) o *feedforward* (FF), son aquellas en las que la información fluye unidireccionalmente desde la entrada hacia la salida sin ciclos, constituyen la forma más extendida. Dentro de este grupo, las redes convolucionales (CNN) destacan por su capacidad para procesar datos con estructura espacial mediante el uso de filtros que detectan patrones locales de forma eficiente [4]. Las redes recurrentes (RNN), por su parte, incorporan conexiones cíclicas que permiten mantener un estado interno a lo largo del tiempo, haciéndolas idóneas para el procesamiento de secuencias y datos temporales [4]. En términos de profundidad, las RNN pueden considerarse las

más profundas de todas las arquitecturas, dado que sus cadenas causales se extienden de manera indefinida [3].

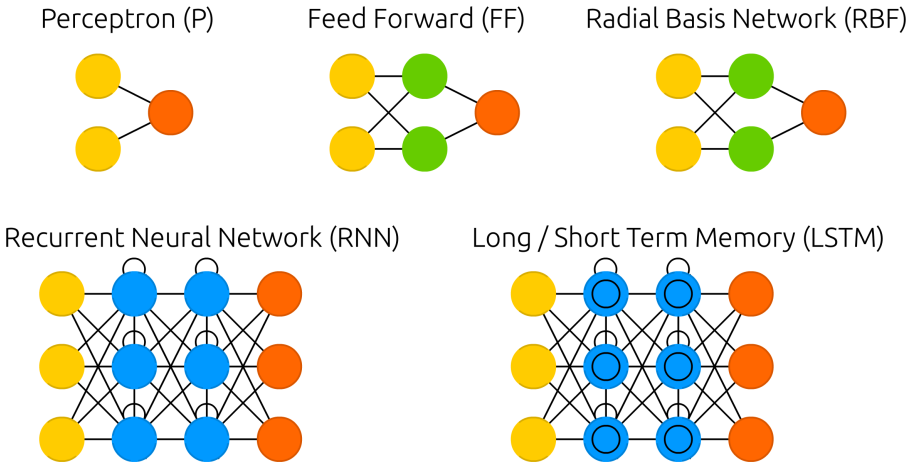

Figura 1.1: Representación de las redes neuronales más comunes y simples. Empezando por el perceptrón, que fue el primer modelo de red neuronal propuesto en el año 1958 por Frank Rosenblatt, hasta llegar a modelos más modernos como las RNN. Fuente: [1].

El campo del aprendizaje automático distingue también entre aprendizaje supervisado, no supervisado y por refuerzo. En el primero, la red dispone de etiquetas para cada muestra de entrenamiento. En el segundo, el objetivo es extraer estructura latente sin supervisión externa, como en los *autoencoders* o las máquinas de Boltzmann restringidas (RBM). El aprendizaje por refuerzo se basa en la interacción de un agente con un entorno, aprendiendo a seleccionar acciones que maximicen una señal de recompensa acumulada [3].

La diferencia fundamental entre las redes clásicas y las redes *deep* radica en su capacidad de representación. Una red con una única capa oculta puede, en teoría, aproximar cualquier función continua con la suficiente anchura —teorema de aproximación universal—, pero resulta ineficiente para capturar estructuras jerárquicas, como las que están presentes en las imágenes o en el lenguaje natural [5]. Las redes profundas, en cambio, aprenden representaciones en múltiples niveles de abstracción: las capas más bajas detectan características primitivas como bordes o frecuencias, mientras que las superiores combinan estas primitivas para reconocer objetos complejos o conceptos semánticos [4]. Esta propiedad de aprendizaje por representación hace que el *Deep Learning* sea especialmente adecuado para problemas en los que la ingeniería manual de características resultaría inviable.

Los modelos de *Deep Learning* exigen grandes volúmenes de datos de entrenamiento y una potencia de cómputo muy superior a la de los modelos clásicos, aspecto que durante décadas limitó su desarrollo. Sin embargo, la disponibilidad creciente de conjuntos de datos masivos y la proliferación de unidades de procesamiento gráfico (GPU) eliminaron estos cuellos de botella y permitieron el despegue definitivo del *Deep Learning* a partir de la segunda mitad de la década de 2000 [3].

En la actualidad, las redes neuronales de *Deep Learning* han revolucionado la inteligencia artificial al demostrar capacidades sin precedentes en la captura de patrones complejos y representaciones jerárquicas [4]. En el campo de la visión por computador, la evolución de las arquitecturas CNN ha marcado hitos sucesivos en la clasificación de imágenes sobre ImageNet: desde AlexNet (2012), que inauguró la era de las CNN profundas en competición, hasta VGGNet, GoogLeNet y ResNet, cada una introduciendo innovaciones arquitectónicas que han impulsado progresivamente el estado del arte [4]. En biología estructural, AlphaFold2 supuso una revolución al predecir la estructura de prácticamente todas las proteínas conocidas con precisión atómica, reduciendo de años a días el tiempo necesario [4]. En procesamiento del lenguaje natural, la irrupción de los grandes modelos de lenguaje (LLM) basados en arquitecturas Transformer —ChatGPT, Llama, Claude 3 o DeepSeek— han demostrado capacidades que igualan o superan el rendimiento humano en amplias variedades de tareas [4].

Sin embargo, el éxito del Deep Learning no está exento de desafíos. Los modelos de última generación requieren cientos de miles de millones de parámetros, con los consiguientes costes computacionales y energéticos, así como dificultades para su despliegue en entornos con recursos limitados. Es en este contexto donde las Tensor Networks emergen como una alternativa prometedora, gracias a su capacidad para representar y comprimir eficientemente estructuras multilineales de alta dimensión, pueden reducir drásticamente el número de parámetros de los modelos de Deep Learning manteniendo su capacidad expresiva [4]. La intersección entre redes neuronales y redes tensoriales, lejos de ser una mera coincidencia formal, refleja una conexión profunda a través de sus estructuras matemáticas multilineales compartidas [4], abriendo el nuevo frente de investigación que este trabajo pretende explorar.

1.2 Introducción a Tensor Networks

Antes de introducir o dar una definición de lo que es una *Tensor Network* (TN), es conveniente aclarar primero la definición de un tensor.

1.2.1 Concepto de tensor

Un tensor lo podemos ver definido de diferentes formas dependiendo del campo en el que estemos trabajando.

Desde un puesto de vista computacional, los tensores son *arrays* multidimensionales que generalizan de forma natural los conceptos de escalar, vector y matriz a dimensiones arbitrariamente superiores. Desde un punto de vista físico-matemático, los tensor son objetos matemáticos de orden superior, que representan relaciones multidimensionales entre distintas variables o grados de libertad. Dicho de otra forma, un tensor de orden N

es un objeto cuyos elementos tienen N índices y están asociados a N vectores base.

$$R^{I_1 \times I_2 \times \cdots \times I_N}$$

donde N es el número de modos y las longitudes $I_1, \ldots, I_N$ representan las dimensiones de cada modo. [4]

Bajo esta definición, los escalares son tensores de orden cero, los vectores son tensores de orden 1, y las matrices son tensores de orden 2; todo caso superior constituye propiamente lo que en la literatura se denomina, tensor de alto orden. En la notación convencional, se distinguen los diferentes objetos según su orden: las letras minúsculas en cursiva (a) denotan escalares, las letras minúsculas en negrita ($\mathbf{a}$) denotan vectores, las letras mayúsculas en negrita ($\mathbf{A}$) denotan matrices, y las letras mayúsculas en tipografía cursiva en negrita ($\boldsymbol{\mathcal{A}}$) denotan tensores de orden superior. [4]

La intuición física detrás de los tensores resulta natural cuando se considera, que muchos fenómenos del mundo real son inherentemente multidimensionales. Una imagen en color, por ejemplo, es un tensor de orden tres: altura, anchura y canales cromáticos. Los datos de resonancia magnética funcional (fMRI) constituyen tensores de orden cuatro, compuestos por vóxeles tridimensionales que varían en el tiempo. En mecánica cuántica, las funciones de onda variacionales de sistemas de muchos cuerpos son, igualmente, tensores de alto orden [4].

El concepto de tensor tiene raíces en el siglo XIX, ligado al desarrollo del cálculo diferencial absoluto por Ricci-Curbastro y Levi-Civita, aunque fue la formulación de la relatividad general por Einstein en 1915 la que consagró los tensores como herramienta fundamental de la física matemática. La notación de índices de Einstein, que convierte la suma sobre índices repetidos en una convención implícita, es todavía hoy estándar en muchos contextos físicos.

$$\boldsymbol{\mathcal{T}} = \sum_{i_1, i_2, \ldots, i_n} T_{i_1 i_2 \ldots i_n} \hat{b_{i_1}} \hat{b_{i_2}} \ldots \hat{b_{i_n}} \tag{1.1}$$

La operación central en el álgebra tensorial es la contracción tensorial. Dados dos tensores $\boldsymbol{\mathcal{T}}$ y $\boldsymbol{\mathcal{R}}$, de orden n y m respectivamente, con elementos $T_{i_1 i_2 \ldots i_n}$ y $R_{j_1 j_2 \ldots j_m}$ y en la misma base ortonormal $\hat{b}_i$, diremos que el tensor $\boldsymbol{\mathcal{C}}$ es la contracción de ambos tensores por sus último q índices cuando:

$$\mathcal{C} = \sum_{i_1, i_2, \ldots, i_{n-q}, j_1, j_2, \ldots, j_{m-q}} C_{i_1 i_2 \ldots i_{n-q}, j_1 j_2 \ldots j_{m-q}} \hat{b}_{i_1} \hat{b}_{i_2} \ldots \hat{b}_{n-q} \hat{b}_{j_1} \hat{b}_{j_2} \ldots \hat{b}_{m-q} \tag{1.2}$$

siendo sus elementos

$$C_{i_1 i_2 \ldots i_{n-q}, j_1 j_2 \ldots j_{m-q}} = \sum_{k_1, k_2, \ldots, k_q} T_{i_1 i_2 \ldots i_{n-q}, k_1 k_2 \ldots k_q} R_{j_1 j_2 \ldots j_{m-q}, k_1 k_2 \ldots k_q} \tag{1.3}$$

De esta definición podemos sacar que la contracción tensorial es la operación mediante la cual dos tensores se contraen en un único tensor a lo largo de sus pares de índices asociados. Existen formas diferentes de contracciones, algunas implican más de dos tensores o un índice repetido en más de dos tensores o incluso repetidos en el mismo tensor. El caso más familiar de contracción tensorial es la multiplicación matricial:

$$\mathbf{AB} = \sum_k A_{ik} B_{kj} \hat{b}_i \hat{b}_j$$

o el producto escalar entre dos vectores:

$$\vec{v} \cdot \vec{w} = \sum_i v_i w_i$$

Entre las operaciones tensoriales fundamentales cabe destacar la traza de una matriz:

$$Tr(A) = \sum_i A_{ii} \tag{1.4}$$

Esto sería la contracción de una matriz consigo misma a través de sus índices repetidos. Debido a esta operación podemos ver que, un tensor también sirve como mapeo entre dos espacios vectoriales. Esto es un tensor, que recibe otro tensor y devuelve un tercer tensor. Por cada índice contraído estamos mezclando componentes del tensor de entrada, reduciendo en 1 el orden del tensor de salida. Por otro lado, los índices que no han sido contraídos aumentarán en 1 el orden del tensor de salida.

1.2.2 Notación diagramática

La representación algebraica de las contracciones tensoriales, aunque precisa, se vuelve rápidamente inmanejable a medida que aumenta el número de tensores y la complejidad de sus conexiones. Fue Roger Penrose [6] quien, a principios de la década de 1970, introdujo la notación diagramática para tensores, proporcionando una alternativa visual que transformó la manera en que se razona sobre estas estructuras. Los diagramas de redes tensoriales son hoy ampliamente utilizados para describir algoritmos cuánticos y algoritmos de aprendizaje automático [4].

La idea central de la notación de Penrose es representar cada tensor como un nodo del que emanan tantas aristas como índices tenga el tensor. Concretamente: un nodo con una sola arista representa un vector $\mathbf{a} \in \mathbb{R}^I$; un nodo con dos aristas representa una matriz $\mathbf{A} \in \mathbb{R}^{I \times J}$; y un nodo con tres aristas representa un tensor $\boldsymbol{\mathcal{A}} \in \mathbb{R}^{I_1 \times I_2 \times I_3}$. Para indicar que un par de índices tensoriales está siendo contraído, ambas aristas se unen mediante una línea. Por ejemplo, la contracción de un tensor de orden uno con uno de orden dos es la multiplicación matriz-vector habitual. Las aristas que no se conectan a ningún otro tensor se denominan aristas libres, y el número de estas aristas en el diagrama resultante es precisamente el orden del tensor final. Dos nodos que no están unidos mediante aristas,

representan el producto tensorial entre ellos.

La notación gráfica tensorial ofrece numerosas ventajas sobre la notación tradicional: en forma gráfica, los índices no necesitan nombres ni etiquetas; operaciones como el producto escalar, la traza tensorial y la contracción pueden expresarse sin notación adicional; y el orden del tensor resultante puede leerse simplemente contando el número de aristas libres. En particular, si en el diagrama no quedan aristas libres tras todas las contracciones, el resultado es necesariamente un escalar. Esta propiedad convierte los diagramas en una herramienta de verificación inmediata de la consistencia dimensional de operaciones complejas [7].

1.2.3 Introducción a las Tensor Networks

Una Tensor Network (TN), es una representación gráfica de una ecuación multilineal entre diferentes tensores. La representación gráfica es la notación diagramática de Penrose, el cual se ha ido adaptando con el tiempo para adaptarla a los requerimientos de diferentes materias, como en física, matemáticas o ciencia computacional [8]. Podemos ver un ejemplo en la Figura 1.2, donde tenemos la tensor network que representa el 2-tensor T_{ip} cuyos elementos se obtienen mediante la operación de contracción

$$T_{ip} = \sum_{j,k,l,m,n,o} A_{ijkl} B_{jm} C_{kmn} D_{lo} E_{nop} \tag{1.5}$$

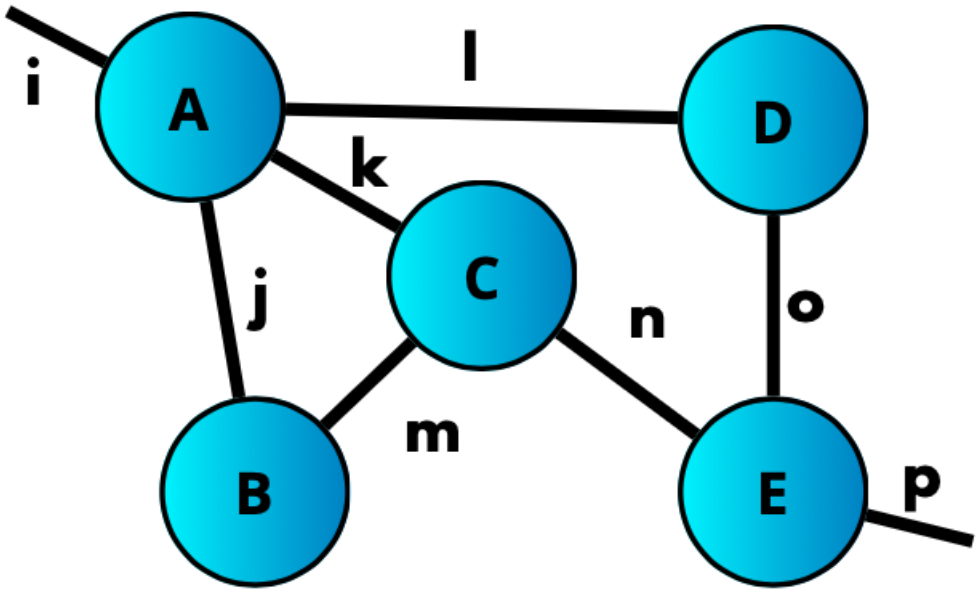

Figura 1.2: Ejemplo de representación diagramática para un tensor. Fuente: [2]

La motivación fundamental para el uso de las Tensor Networks es de naturaleza computacional. Un tensor de orden N con dimensión d en cada nodo tiene d^N componentes, un número que crece exponencialmente con el orden del tensor, haciendo que su almace-

namiento y manipulación directos sean computacionalmente prohibitivos; este fenómeno se conoce como la *maldición de la dimensionalidad*. Las Tensor Networks resuelven este problema representando el tensor original, no de forma explícita, sino como el resultado de contraer un conjunto de tensores de menor orden, cada uno con un número de parámetros manejable, de modo que la complejidad resultante escala de forma polinomial en lugar de exponencial [4, 7].

La topología de la red, determina qué tipo de correlaciones puede capturar eficientemente y a qué coste computacional. Los formatos más habituales en la literatura son los siguientes. El *Tensor Train* (TT), también denominado *Matrix Product State* (MPS) en física cuántica, dispone los núcleos tensoriales en cadena lineal; para un tensor $\boldsymbol{\mathcal{X}} \in \mathbb{R}^{I_1 \times \cdots \times I_N}$, la descomposición TT expresa sus elementos como

$$\mathcal{X}_{i_1 i_2 \ldots i_N} \approx \sum_{r_1, r_2, \ldots, r_{N-1}}^{R_1, R_2, \ldots, R_{N-1}} \mathcal{G}^{(1)}{}_{1 i_1 r_1} \mathcal{G}^{(2)}{}_{r_1 i_2 r_2} \mathcal{G}^{(3)}{}_{r_2 i_3 r_3} \ldots \mathcal{G}^{(N)}{}_{r_{N-1} i_N 1} \tag{1.6}$$

donde cada $\mathcal{G}^{(n)} \in \mathbb{R}^{R_{n-1} \times I_n \times R_n}$ es un nodo de la red, $r_1, \ldots, r_{N-1}$ son los índices virtuales sobre los que se suma, y $R_1, \ldots, R_{N-1}$ son sus dimensiones, denominadas rangos TT o dimensiones de enlace [4]. La dimensión de enlace es el hiperparámetro que controla la relación entre exactitud de la aproximación y coste computacional; para un valor suficientemente grande, el MPS puede representar cualquier tensor [7]. Las redes tensoriales jerárquicas (TTN y MERA) adoptan topologías de árbol, capturando correlaciones de largo alcance que el MPS representa con mayor dificultad. Los estados entrelazados por pares proyectados (PEPS) extienden la lógica del MPS a redes bidimensionales, naturalmente adaptadas a datos con estructura espacial [9, 4]. La selección del formato adecuado para una tarea concreta depende tanto de la estructura de correlaciones que se desea capturar como de las restricciones computacionales disponibles.

Capítulo 2. OBJETIVOS

2.1 Objetivos generales

El objetivo general del trabajo consiste en ampliar el conocimiento actual sobre la aplicación de las Tensor Networks como paradigma alternativo al deep learning convencional en tareas de clasificación de imágenes, evaluando su viabilidad, rendimiento y eficiencia mediante la implementación y experimentación con distintas arquitecturas tensoriales.

Para ello, el proyecto contempla el estudio en profundidad del estado del arte en modelos de inteligencia artificial basados en Tensor Networks, la implementación de al menos dos arquitecturas tensoriales a partir de la literatura científica, su entrenamiento y evaluación utilizando recursos de computación de altas prestaciones (HPC) del servidor Lorca de la Universidad Europea, y la comparación de sus resultados frente a modelos clásicos de deep learning sobre conjuntos de datos de referencia.

De forma complementaria, el proyecto persigue adquirir experiencia práctica en el uso de herramientas computacionales propias del ámbito de la investigación en inteligencia artificial, incluyendo el manejo de entornos HPC, el uso de librerías especializadas como PyTorch y TensorKrowch, y las buenas prácticas de documentación y reproducibilidad del código científico.

2.2 Objetivos específicos

1. Realizar una revisión del estado del arte de los modelos de inteligencia artificial basados en Tensor Networks aplicados a la clasificación de imágenes, analizando las arquitecturas más relevantes y sus principales resultados.

2. Estudiar en detalle distintos modelos tensoriales para clasificación de imágenes, con el fin de comprender su funcionamiento y sus diferencias fundamentales.

3. Implementar al menos dos modelos de inteligencia artificial basados en Tensor Networks para tareas de clasificación de imágenes, a partir de descripciones presentes en la literatura científica.

4. Entrenar y evaluar los modelos implementados utilizando recursos de computación de altas prestaciones (HPC), familiarizándose con el uso de servidores, entornos de ejecución y herramientas básicas de gestión de trabajos.

5. Comparar el rendimiento de los modelos basados en Tensor Networks con modelos de inteligencia artificial convencionales, empleando conjuntos de datos de referencia en clasificación de imágenes.

6. Analizar los resultados obtenidos en términos de precisión, eficiencia computacional y comportamiento del entrenamiento, identificando las principales ventajas y limitaciones de los enfoques tensoriales.

7. Documentar el desarrollo del proyecto, describiendo de forma clara los modelos estudiados, las implementaciones realizadas y los resultados obtenidos.

8. Preparar y organizar un repositorio de código que recoja las implementaciones y experimentos realizados, garantizando su claridad, reproducibilidad y correcta documentación.

2.3 Objetivos que quedan fuera del proyecto

- Estudiar modelos de inteligencia artificial no aplicados a la clasificación de imágenes y que no estén basados en Tensor Networks.
- Evaluar los modelos en conjuntos de datos distintos de los considerados en el proyecto, o realizar comparaciones extensivas en múltiples benchmarks adicionales.
- Ejecutar los modelos en hardware cuántico real, más allá de enfoques cuántico-inspirados ejecutados en sistemas clásicos.
- Desarrollar aplicaciones orientadas a entornos industriales o sistemas en producción a partir de los modelos estudiados.

2.4 Beneficios del proyecto

Desde el punto de vista científico, este proyecto contribuye a ampliar el conocimiento empírico sobre las Tensor Networks como herramienta de aprendizaje automático. Si bien el fundamento teórico de estas arquitecturas está bien establecido en el ámbito de la física cuántica y matemática, su comportamiento práctico en tareas de clasificación de imágenes sigue siendo un área activa de investigación. El trabajo aportará evidencia experimental concreta sobre estas cuestiones.

Desde el punto de vista computacional, el proyecto favorece el desarrollo de modelos de IA más eficientes en el uso de parámetros. Los modelos basados en Tensor Networks permiten, en principio, representar funciones complejas con un número significativamente menor de parámetros que las redes neuronales profundas convencionales. Esto tiene implicaciones directas sobre el coste energético y computacional del entrenamiento, un aspecto de creciente relevancia en la investigación en inteligencia artificial.

Desde el punto de vista formativo, el proyecto supone una experiencia integral en investigación aplicada: comprende la revisión crítica de literatura científica, el diseño e implementación de experimentos reproducibles, el uso de infraestructuras HPC y el aprendizaje de herramientas y flujos de trabajo propios del ámbito profesional de la investigación en IA.

Estos conocimientos y competencias son directamente transferibles a entornos académicos y laborales en el campo de la inteligencia artificial y la computación científica

Capítulo 3. DESARROLLO DEL TFG

3.1 Planificación del trabajo fin de grado

Figura 3.1: Planificación por semanas del TFG, cada circulo representa una semana teniendo febrero 3 semanas (porque empiezo el 9 de Febrero), marzo 4 semanas, abril cuatro semanas y por último mayo tendrá otras cuatro semanas. De esta manera se cumplen entre 500 y 600 horas dedicadas al TFG.

- **Semanas 1–3: Introducción y fundamentos de Tensor Networks**

  Durante las primeras semanas se adquirirán los conocimientos fundamentales y teóricos sobre Tensor Networks.

  - Estudio de la notación y representaciones básicas de Tensor Networks mediante material audiovisual.

- Lectura y análisis de artículos científicos relevantes, con especial atención a modelos tensoriales aplicados a clasificación de imágenes.
- Estudio de apuntes y material teórico relacionado con Tensor Networks y su conexión con la física de sistemas cuánticos.

- **Semanas 4–6: Estudio de modelos MPS para clasificación de imágenes**

  En esta etapa se profundizará en el uso de Matrix Product States como modelos de clasificación de imágenes:

  - Análisis del funcionamiento de clasificadores basados en MPS y estudio de sus fuentes de error.
  - Revisión de implementaciones existentes y comprensión de los procedimientos de entrenamiento y evaluación.
  - Búsqueda y selección de conjuntos de datos adecuados en plataformas como Kaggle o Hugging Face.

- **Semanas 7–8: Formación en herramientas computacionales**

  Durante este periodo se adquirirá el conocimiento práctico necesario para el desarrollo del proyecto:

  - Aprendizaje de comandos básicos de Bash y trabajo en entornos de servidor.
  - Uso de GitHub para el control de versiones y la organización del código.
  - Estudio de buenas prácticas de organización de proyectos y documentación.
  - Aprendizaje en profundidad de PyTorch para la implementación de modelos de inteligencia artificial.

- **Semanas 9–13: Implementación y experimentación**

  En esta fase se llevará a cabo la implementación y entrenamiento de los modelos seleccionados:

  - Implementación de modelos basados en Tensor Networks para clasificación de imágenes.
  - Entrenamiento de los modelos utilizando recursos de computación de altas prestaciones (HPC).
  - Evaluación del rendimiento de los modelos y comparación con modelos de inteligencia artificial convencionales.

- **Semanas 13–15: Análisis de resultados y redacción**

  En la etapa final se realizará el análisis de los resultados obtenidos y la documentación del trabajo:

  - Análisis crítico de los resultados y discusión de las conclusiones.
  - Redacción de la memoria del Trabajo Fin de Grado.
  - Organización final del repositorio de código y preparación de la entrega.

3.2 Descripción de la solución, metodologías y herramientas empleadas

3.2.1 Recursos requeridos

A continuación se enumeran los recursos técnicos utilizados para la ejecución del trabajo:

- Recursos computacionales:
  - Servidor HPC Lorca de la Universidad Europea de Madrid: para el entrenamiento de los modelos con recursos de computación de altas prestaciones.
  - Ordenador personal: para el desarrollo, pruebas locales y escritura de la memoria.
- Herramientas de software
  - Python (lenguaje de programación principal).
  - PyTorch (framework de deep learning).
  - TensorKrowch (librería para implementación de Tensor Networks).
  - NumPy, SciPy, Matplotlib, Seaborn (librerías científicas y de visualización).
  - GitHub (control de versiones y gestión del repositorio de código).
  - Bash / Linux (gestión del entorno HPC y automatización de trabajos).
  - Docker / entornos virtuales (gestión de dependencias y reproducibilidad).
- Recursos bibliográficos y de datos:
  - Artículos científicos de referencia (véase sección de Referencias).
  - Conjuntos de datos públicos: MNIST, OlivettiFaces (obtenidos de repositorios como Kaggle o Hugging Face).

3.3 Resultados del TFG

Conforme a los objetivos específicos, describe los resultados finales obtenidos.

Puedes añadir una descripción de cambios durante el TFG respecto a los objetivos iniciales, y comentarios que quieras incluir de cómo has desarrollado las distintas actividades.

Capítulo 4. DISCUSIÓN

Esta sección es más habitual en trabajos de tipo "científico" o de "investigación", donde uno presenta brevemente los resultados principales y los discute, pero también puede utilizarse en otro tipo de trabajos.

Puedes incluir secciones específicas para discutir cuestiones como: limitaciones del estudio, limitaciones de la tecnología empleada, cambios respecto a objetivos planteados inicialmente.

Puedes incluir respuestas a preguntas del tipo: ¿la metodología inicialmente pensada ha sido útil?, ¿he tenido que adaptarme a cambios a lo largo del proyecto?, ¿qué cambios han sido y cómo he adaptado el proyecto para poder manejar esos cambios?, ¿qué impacto ha tenido el resultado de mi proyecto?

Capítulo 5. CONCLUSIONES

5.1 Conclusiones del trabajo

Breve descripción objetiva del resultado en relación al objetivo general de tu TFG.

5.2 Conclusiones personales

Describe tus impresiones y experiencia personal durante el desarrollo del TFG, o destacar la importancia que tiene el tema para ti, lo que has aprendido, o la trascendencia que ha tenido para ti o para otros este trabajo.

Capítulo 6. FUTURAS LÍNEAS DE TRABAJO

Es importante destacar en este apartado las líneas con las que se podría continuar tu trabajo. Indica todo lo que has anotado como futuro trabajos durante el desarrollo del TFG, o aquellos aspectos que estaban fuera del alcance, pero que son interesantes para desarrollar a futuro el valor de los resultados de tu trabajo.

REFERENCIAS

[1] Fred Van Veen and Stefan Leijnen. The neural network zoo. `https://www.asimovinstitute.org/neural-network-zoo`, 2019. Asimov Institute. Accessed: 2026-03-19.

[2] Alejandro Mata Ali, Iñigo Perez Delgado, and Aitor Moreno Fdez. de Leceta. Quantum-inspired Techniques in Tensor Networks for Industrial Contexts. *arXiv e-prints*, page arXiv:2404.11277, April 2024.

[3] Jürgen Schmidhuber. Deep learning in neural networks: An overview. *Neural networks*, 61:85–117, 2015.

[4] Maolin Wang, Yu Pan, Zenglin Xu, Guangxi Li, Xiangli Yang, Danilo Mandic, and Andrzej Cichocki. Tensor networks meet neural networks: A survey and future perspectives. *arXiv preprint arXiv:2302.09019*, 2023.

[5] Andrzej Cichocki, Namgil Lee, Ivan Oseledets, Anh-Huy Phan, Qibin Zhao, and Danilo P Mandic. Tensor networks for dimensionality reduction and large-scale optimization part 1 low-rank tensor decompositions. *Foundations and Trends in Machine Learning*, 9(4-5):249–429, 2016.

[6] Roger Penrose et al. Applications of negative dimensional tensors. *Combinatorial mathematics and its applications*, 1(221-244):3, 1971.

[7] E. Miles Stoudenmire and David J. Schwab. Supervised learning with quantum-inspired tensor networks, 2017.

[8] Jacob Biamonte and Ville Bergholm. Tensor networks in a nutshell, 2017.

[9] Amandeep Singh Bhatia, Mandeep Kaur Saggi, and Sabre Kais. Application of quantum-inspired tensor networks to optimize federated learning systems. *Quantum Machine Intelligence*, 7(1):12, 2025.

ANEXOS

Sirven para incluir documentación complementaria (planos, circuitos, código, ficheros de configuración, especificaciones técnicas y hojas de características, fichas explicativas, resultado de encuestas, reglamentación y normativas requeridas, etc.).

[PÁGINA INTENCIONADAMENTE EN BLANCO]